

단일 채널 오디오에서의 음성 분리 및 성문 대조 비교 시스템 구축을 위한 심층 기술 연구 보고서

1. 서론: 음향 장면 분석과 화자 식별 파이프라인의 통합적 이해

현대의 복잡한 청각적 환경에서 특정 화자의 음성을 분리하여 신원을 확인하는 작업은 이른바 '칵테일 파티 문제(Cocktail Party Problem)'를 해결하는 인공지능 및 음성 신호 처리 분야의 핵심 과제이다¹. 단일 마이크로폰(Single-channel)을 통해 수음된 혼합 오디오로부터 배경 소음과 타인의 간섭 음성을 제거하고, 타겟 화자의 순수한 발화만을 추출한 뒤 고유한 생체 인식적 특징인 성문 패턴(Voiceprint, 화자 임베딩)을 생성하여 다른 화자와 대조 비교하는 일련의 과정은 극도의 정밀성과 아키텍처적 일관성을 요구한다¹.

본 보고서는 소리에서 음성을 분리하여 성문 패턴을 만들고 다른 성문과 대조 비교하는 결과를 산출하는 통합 프로젝트를 수행하는 데 필요한 모든 알고리즘, 아키텍처, 훈련 방법론, 수학적 최적화 기법, 그리고 시스템 통합 시 발생하는 잠재적 위험 요소를 총망라하여 분석한다. 본 프로젝트의 전체 시스템 파이프라인은 크게 세 가지 핵심 모듈로 구성된다. 첫째, 다중 화자의 겹친 음성(Overlapped speech) 및 배경 소음으로부터 개별 화자의 깨끗한 음성을 추출하는 음성 분리(Speech Separation) 및 전처리 단계, 둘째, 분리된 음성의 시계열 파형으로부터 화자 고유의 성문 특징을 고차원 벡터 잠재 공간(Latent space)으로 압축하는 화자 임베딩(Speaker Embedding) 단계, 셋째, 추출된 임베딩 간의 각도 및 거리 기반 유사도를 측정하고 환경적 편차를 정규화하여 동일인 여부를 최종 판별하는 대조 비교(Speaker Verification) 단계이다¹. 나아가 최근 급증하는 합성 음성 공격에 대비한 딥페이크 탐지(Anti-Spoofing) 메커니즘의 결합까지 포괄적으로 다룬다⁷.

2. 혼합 음원에서의 음성 분리(Speech Separation) 기술 및 모델 아키텍처

음성 분리는 혼합된 오디오 신호 내에서 개별 소스의 신호를 독립적으로 복원하는 고도의

역문제(Inverse problem)이다. 단일 채널 음성 분리의 수학적 모델은 T 개의 샘플을 가진 혼합

신호 $x \in \mathbb{R}^{1 \times T}$ 로부터 C 개의 소스 $s_1, \dots, s_C \in \mathbb{R}^{1 \times T}$ 를 추정하는 것으로 정의된다¹⁰. 방정식은 통상적으로 다음과 같이 표현된다:

$$x(t) = \sum_{c=1}^C (s(c, t) + h(c, t)) + n(t)$$

여기서 s 는 직접 경로 신호, h 는 실내 잔향(Reverberation) 반사음, n 은 배경 소음을

의미한다⁴. 음성 분리 모델은 입력된 x 로부터 타겟 화자의 파형 $\hat{s}$ 를 추정해야 한다.

2.1 마스크 기반 신경망(Mask-based Neural Networks)과 훈련 메커니즘

최신 딥러닝 기반 음성 분리는 주로 심층 군집화(Deep Clustering) 방식에서 발전하여, 종단간(End-to-End) 학습이 가능한 마스크 기반 인코더-디코더(Encoder-Decoder) 구조를

채택하고 있다¹. 입력 혼합 신호 x 는 학습 가능한 인코더 $E(\cdot)$ (주로 1D 합성곱 계층을 사용)를 통해 F 개의 특징을 가진 시간-주파수 유사 공간으로 변환된다 ($X \in \mathbb{R}^{F \times T}$)¹⁰. 이후

마스커(Masker) 신경망이 화자별 특징 마스크 M_i 를 연산하고, 이를 인코딩된 특징 X 와

요소별 곱(Element-wise multiplication, $\odot$)을 수행하여 특정 화자의 신호만을 활성화한다. 마지막으로 학습된 디코더 $D(\cdot)$ 가 이를 다시 시간 도메인의 파형으로 복원하는 구조이다¹⁰.

이 과정에서 딥러닝 모델이 직면하는 가장 근본적인 난제는 '순열 문제(Permutation Problem)'이다. 모델의 다중 출력 포트가 실제 어떤 화자의 정답(Ground Truth)과 매칭되어야 하는지 사전에 알 수 없기 때문이다¹⁰. 이를 해결하기 위해 순열 불변 훈련(Permutation Invariant Training, PIT) 기법이 필수적으로 적용된다. PIT는 모델 훈련 시 모든 가능한 출력-정답 조합에 대해 오차를 계산하고, 그중 최소 오차를 반환하는 순열 조합을 동적으로 선택하여 가중치를 업데이트한다¹. 훈련을 위한 주요 목적 함수로는 척도 불변 신호 대 잡음비(Scale-Invariant Signal-to-Noise Ratio, SI-SNR)가 널리 사용되며, 이는 신호의 진폭 스케일 변화에 영향을 받지 않고 파형의 구조적 복원력을 평가한다:

$$\text{SI-SNR} = 10 \log_{10} \frac{\|\alpha s\|^2}{\|\hat{s} - \alpha s\|^2}$$

여기서 타겟 신호 s 와 추정 신호 $\hat{s}$ 간의 투영 계수 $\alpha = \frac{\langle \hat{s}, s \rangle}{\|s\|^2}$ 이다¹⁰.

2.2 SOTA 음성 분리 모델의 진화와 성능 비교

프로젝트의 요구 성능(지연 시간, 처리량, 정확도)에 맞춰 적절한 음성 분리 아키텍처를 선택하는 것은 성문 패턴 추출의 품질을 결정짓는 핵심 단계이다. 과거의 통계적 모델(ICA, NMF 등)의 한계를 넘어 데이터 주도형(Data-driven) 신경망 모델이 현재 기술의 주축을 이루고 있다¹.

분리 모델 아키텍처	핵심 구조 및 기술적 특징	프로젝트 적용 시 장단점 분석	참고 문헌
Conv-TasNet	1D CNN(시간 도메인) 및 팽창 합성곱(Dilated Convolution) 적용	이상적인 시공간 마스킹을 최초로 가능함. 비교적 연산이 가벼우나,	10

		매우 긴 시퀀스에서의 문맥 파악과 장기 의존성(Long-term dependency) 모델링에 한계가 있음.	
SepFormer	Transformer (다중 헤드 자기 주의, Multi-head Attention) 기반	RNN을 배제하고 병렬 처리를 극대화하여 WSJ0-2/3mix 데이터셋에서 SOTA 달성(SI-SNRi 22.3dB). 성능은 압도적이나 어텐션 연산의 2차(Quadratic) 메모리 복잡도로 인해 자원 소모가 큼.	10
RE-SepFormer	잠재 공간 축소 기반 효율적(Resource-Efficient) Transformer	비중첩(Non-overlapping) 블록을 사용하고 청크(Chunk)별 압축 잠재 요약을 처리하여 메모리와 추론 시간을 획기적으로 감축. 긴 길이의 혼합 음성 및 회의 데이터 처리에 매우 적합함.	17
MossFormer	Hybrid 접근 (Self-attention + Recurrent Network)	거시적 장기 의존성(Self-attention)과 미세 규모의 순환 패턴(Recurrent pattern)을 통합적으로 포착.	10

		복잡한 미세 왜곡을 보정하여 성능을 극대화함.	
Mamba-TasNet (DPMamba)	구조적 상태 공간 모델(Structured State Space Models, SSMs)	Transformer의 성능을 능가하거나 유지하면서도, 시퀀스 길이에 대해 선형적인(Linear) 시간 복잡도를 갖는 Mamba를 활용. 메모리 효율과 성능의 완벽한 균형을 제공함.	14
Codecformer-EL	사전 훈련된 신경 오디오 코덱(Neural Audio Codec) 결합형 모델	파형 대신 고도로 압축된 임베딩 도메인 내에서 분리를 수행하여 훈련 속도와 계산 비용을 2배 이상 감축함. 통신 대역폭이 제한된 모바일 및 에지(Edge) 환경의 백엔드 시스템 구축 시 유리함.	19

프로젝트 도입 통찰: 만약 오프라인 환경에서 최고 수준의 무결점 화자 분리가 요구되는 포렌식 수준의 프로젝트라면 **SepFormer**나 **MossFormer**를 채택해야 한다¹⁵. 반면, 실시간 화자 대조가 필요하거나 장시간의 회의(Continuous Speech Separation, CSS) 오디오를 스트리밍으로 분리해야 한다면, 시퀀스 길이가 길어질수록 연산량이 폭증하는 트랜스포머 대신 선형 복잡도를 제공하는 **Mamba-TasNet**이나 오디오 코덱 임베딩 기반의 **Codecformer-EL**을 채택하는 것이 아키텍처적 병목을 예방하는 필수 전략이다¹⁴.

2.3 연속 음성 분리(CSS) 및 무감독 혼합 학습(MixIT) 전략

실제 상황의 오디오는 짧고 고정된 길이로 자르기 어렵다. 이를 해결하기 위해 연속 음성 분리(Continuous Speech Separation, CSS) 슬라이딩 윈도우 기법이 적용되어야 한다²⁰. 그러나 CSS는 윈도우 간 겹침(Overlap) 구간의 유사도를 바탕으로 화자를 추적하므로, 침묵이 길어질 경우 추적이 끊기는 한계가 존재한다²⁰. 또한 현실의 음성 데이터는 깨끗한 단일 화자 정답(Ground truth) 오디오를 얻기 불가능하다는 문제(Cross-talk)가 있다. 이러한 도메인 격차를 극복하기 위해, 대상 도메인의 혼합 음성 두 개를 단순히 더해 '혼합물의 혼합물(MoM)'을

만들고, 이를 원래의 혼합물 두 개로 분리하도록 훈련하는 무감독 기반 혼합 불변 훈련(Mixture Invariant Training, MixIT) 프레임워크 또는 AC-SIM과 같은 데이터 시뮬레이션 파이프라인의 도입이 현업 모델 성능 최적화에 강하게 권장된다³.

3. 음질 복원 및 전처리 프론트엔드 (Speech Enhancement & VAD)

순수한 음성 분리 모델은 겹친 화자들을 떼어내는 데에는 탁월하지만, 단일 마이크 특성상 잔향(Reverberation)이나 비정형 배경 소음이 개입된 상황에서는 필연적으로 노이즈를 함께 남기거나 신호를 왜곡시킨다. 따라서 화자 임베딩 생성 전 단계에서 이를 교정하는 전처리가 요구된다.

3.1 딥러닝 기반 실시간 음성 향상 (Speech Enhancement)

분리된 신호의 인지적 품질(PESQ, STOI 등)을 복구하기 위해 **DeepFilterNet**과 같은 실시간 소음 억제 프레임워크를 전처리 파이프라인으로 결합해야 한다²². **DeepFilterNet**은 PyTorch 및 ONNX 기반으로 8~48kHz 환경을 지원하며, 저지연(Low-latency) 스트리밍 구조로 설계되어 CPU 환경에서도 실시간 작동이 가능할 정도로 파라미터가 가볍게 최적화되어 있다²². 이는 음성 분리 직후 배경 소음이 임베딩 벡터를 오염시키는 것을 1차적으로 차단한다. 또한 최상위 수준의 보정이 필요한 경우, 식별적(Discriminative) 분리가 만든 비자연스러운 왜곡과 노이즈를 확산 모델(Diffusion Model) 기반의 생성적 교정기(Generative Corrector, GeCo)로 1단계(Single-step) 역과정을 통해 제거하는 최신 기법이 SI-SNR을 극적으로 향상시킬 수 있다².

3.2 음성 구간 검출 (Voice Activity Detection, VAD)

긴 길이의 오디오에서 비음성(침묵, 단순 소음) 구간을 사전에 제거하지 않으면 화자 임베딩 추출 시 치명적인 노이즈 임베딩이 섞이게 된다. 파이프라인의 가장 앞단에는 엄격한 메모리 및 지연 제약 하에서도 견고하게 동작하는 **Silero VAD** 혹은 **Pyannote Audio**와 같은 경량 VAD 모델을 배치하여 유효 발화 구간(Segment)만을 타겟으로 분리망에 공급해야 한다²⁶.

4. 성문 패턴(Voiceprint) 생성 및 화자 임베딩 추출

음성 분리와 향상 단계를 거쳐 추출된 타겟 화자의 발화 파형은 그 길이가 가변적이며 차원이 방대하다. 성문 대조 비교를 수학적으로 수행하기 위해서는 이 가변 시계열 데이터를 고정된 차원의 조밀한 벡터(Fixed-length dense vector)로 변환하는 '화자 임베딩(Speaker Embedding)' 기술이 필요하다. 훌륭한 임베딩 공간에서는 동일 화자의 벡터들이 강력하게 밀집(Intra-class compactness)하고, 서로 다른 화자의 군집은 멀리 떨어지게(Inter-class discrepancy) 된다⁵.

4.1 화자 임베딩 백본 네트워크 아키텍처

현대 화자 인식 시스템은 통계적 방식(i-vector)을 완전히 대체하고 심층 신경망을 활용하고 있다. 이 프로젝트에서 채택할 수 있는 벤치마크 최고 수준의 백본 아키텍처는 다음과 같다.

화자 임베딩 모델	아키텍처 핵심 설계	강점 및 활용 시나리오	참조 문헌
ECAPA-TDNN	1D Res2Net 블록 + Squeeze-and-Excit	다중 계층(얇은 층과 깊은 층)의 특징을	⁵

	ation(SE) 채널 주의 기법 적용	집계하여 컨텍스트를 풍부하게 반영. 화자 인식 분야의 사실상 표준 베이스라인으로, 노이즈에 강건하며 개방형 집합(Open-set) 성능이 우수함.	
ERes2Net & ERes2NetV2	2D Res2Net 기반 다중 스케일 국소/전역 특징 융합 및 어텐션 기법(AFF)	단기 발화(Short-duration, 2~3초 미만) 인식 시의 성능 하락 문제를 정면으로 돌파. 채널 차원을 확장하되 중복 구조를 가지치기하여 연산 효율을 높임(VoxCeleb1-O EER 0.61%).	32
CAM++	밀집 연결 TDNN (D-TDNN) + 문맥 인식 다중 세분성 풀링(Multi-granularity pooling)	매우 낮은 연산량으로 다양한 시점의 특징을 포착. 에지 기기 등 제한된 자원 환경에서 대규모 화자를 식별할 때 최적의 효율성 발휘.	32
Whisper-PMFA	OpenAI Whisper 인코더 + PMFA(Partial Multi-Scale Feature Aggregation) 투영 헤드	수만 시간의 다국어 범용 음성 인식(ASR) 데이터로 사전 학습된 언어 모델의 지식을 화자 인식으로 전이(Transfer learning). 다국어	38

		화자 및 복잡한 언어 환경에서 매우 강력한 강건성을 지님.	
--	--	---	--

프로젝트 도입 통찰: 음성 분리 알고리즘을 통과한 출력물은 종종 분절되어 길이가 2~3초 미만으로 짧아지는 경우가 잦다. 과거의 X-Vector나 단순 ResNet은 이렇게 짧은 오디오에서 신뢰할 수 없는 임베딩을 생성하는 반면, **ERes2NetV2**는 불완전한 시간-주파수 정보 하에서도 채널 확장과 다중 스케일 구조를 통해 치명적인 성능 저하를 방어하므로 본 프로젝트의 성문 추출 모듈로 가장 추천된다³³. 한편 다국어 화자가 뒤섞인 글로벌 회의 데이터를 다룬다면, 풍부한 음향 지식을 내재화한 **Whisper-PMFA**를 채택하는 것이 월등한 식별력을 제공할 것이다³⁸.

4.2 잠재 공간 최적화를 위한 수학적 손실 함수 (Loss Functions)

임베딩 백본 네트워크가 구조적 특징을 추출한다면, 손실 함수(Loss Function)는 벡터들이 매핑되는 잠재 공간의 기하학적 형태를 강제한다. 전통적인 소프트맥스(Softmax)는 클래스 간 뚜렷한 마진(Margin)을 보장하지 않아 화자 검증과 같은 열린 집합(Open-set) 문제에서 성능의 한계를 보인다⁴². 본 프로젝트에서는 각도 및 확률론적 마진 패널티를 부여하는 최신 목적 함수를 훈련 과정에 필수적으로 반영해야 한다.

가산 각도 마진 손실 (ArcFace / Additive Angular Margin Loss)

ArcFace는 화자 인식(SV) 및 안면 인식 분야의 패러다임을 바꾼 혁신적인 손실 함수이다²⁹. 이

기법은 임베딩 벡터($\mathbf{x}$)와 정답 클래스의 가중치 중심 벡터($\mathbf{W}$)를 각각 L_2 정규화하여 벡터의 크기(Norm)를 스케일 s 를 갖는 초구(Hypersphere) 표면에 고정시킨다²⁹. 분류 시 두 벡터 사이의 각도 θ 를 코사인 유사도로 산출하는데, ArcFace는 훈련 시 타겟 클래스의 각도에 인위적인 가산 각도 마진(Additive angular margin) m 을 강제로 더하여($\cos(\theta + m)$) 결정 경계(Decision boundary)를 엄격하게 만든다²⁹.

$$L_{ArcFace} = -\frac{1}{N} \sum_{i=1}^N \log \frac{e^{s(\cos(\theta_{y_i} + m))}}{e^{s(\cos(\theta_{y_i} + m))} + \sum_{j=1, j \neq y_i}^C e^{s \cos(\theta_j)}}$$

이 공식은 초구면 상의 측지선 거리(Geodesic distance)와 정확히 일치하는 명확한 기하학적 해석을 갖는다. 마진 m 의 존재는 모델로 하여금 정답 클래스에 더 가깝게(Intra-class compactness 극대화), 오답 클래스로부터는 더 멀어지도록(Inter-class discrepancy 극대화) 강한 패널티를 부여하여, 훈련 수렴성을 안정화하고 극한의 분별력을 끌어낸다²⁹.

Q-Margin (α -divergence 기반 마진)

최신 연구에서는 기하학적으로 로짓(Logit)을 수정하는 ArcFace나 CosFace의 접근을 넘어서, 확률 분포의 참조 척도(Reference measure)에 마진을 도입하는 Q-Margin 모델링이

등장하였다⁴³. ArcFace가 로짓의 기하학적 수정이라는 '휴리스틱(Heuristic)' 성향을 띠는 반면, Q-Margin은 사전 확률(Prior probabilities)인 레퍼런스 측정값 $q_y = \exp(-s \cdot m)$ 을

조정하여 엄격한 학습 목표를 생성한다. 이를 통해 모델은 희소성(Sparsity)을 유도하는 α -divergence의 이점을 보존하면서도 더 자연스러운 확률론적 결정 마진을 확보할 수 있다⁴³.

대조 학습(Contrastive Learning)과의 융합: AAMSupCon

성문 생성 시 같은 화자의 다양한 발화 조건(깨끗한 음성, 분리된 음성, 노이즈 낀 음성) 간의 일관성을 유지하기 위해, 지도 대조 학습(Supervised Contrastive Learning)에 ArcFace의 가산 각도 마진을 결합한 AAMSupCon 방식도 제안된다⁴⁴. 이는 하나의 앵커(Anchor)에 대해 다수의 양성 샘플(Positive samples)을 군집화하여 스피커 임베딩의 분리 가능성을 극대화한다⁴⁴.

5. 성문 대조 비교(Speaker Verification) 백엔드 및 점수 정규화

두 성문(사전 등록된 Target 화자의 임베딩 e 와 음성 분리 과정을 거쳐 들어온 Test 임베딩 t)의 일치 여부를 판별하는 대조 비교 스코어링은 일반적으로 코사인 거리(Cosine Distance/Similarity)를 내적 연산하여 수행된다¹⁶. 하지만 실무 환경에서 이 원시 유사도 점수(Raw score)만으로 고정된 임계값(Threshold)을 적용해 동일한 여부를 판정(Hard thresholding)하면 치명적인 실패율을 겪게 된다. 화자의 생리적 상태, 발화 길이, 잔존 소음, 그리고 무엇보다 음성 분리 모델이 유발한 아티팩트로 인해 임베딩 점수의 편차가 매우 불균일하기 때문이다.

5.1 적응형 대칭 점수 정규화 (AS-Norm, Adaptive Symmetric Score Normalization)

이러한 스코어 불균형과 편향을 획기적으로 교정하기 위해 AS-Norm 처리가 백엔드 파이프라인의 필수 불가결한 정규화 기법으로 요구된다⁶. 과거에 쓰이던 T-norm (Test normalization)이 테스트 세그먼트만을 기준으로 정규화했다면, AS-Norm은 대칭성(Symmetry)을 바탕으로 화자 모델과 테스트 모델 양쪽 모두의 컨텍스트를 반영한다⁵². 수학적 메커니즘을 살펴보면, AS-Norm은 사전에 구축된 임포스터(Impostor, 사칭자)

코호트(Cohort) 데이터베이스를 활용한다. 등록 모델 e 와 테스트 발화 t 각각에 대해 코호트 내에서 가장 점수가 높은 상위 N 개의 가장 혼동하기 쉬운 발화만을 적응적으로 선택(Adaptive cohort selection)하여 평균(μ)과 표준편차(σ)를 계산한다⁶. 최종 정규화된 점수 $S_{AS-Norm}$ 는 다음의 대칭 공식을 통해 산출된다:

$$S_{AS-Norm} = \frac{1}{2} \left(\frac{S(e, t) - \mu_{\text{cohort}}(e)}{\sigma_{\text{cohort}}(e)} + \frac{S(e, t) - \mu_{\text{cohort}}(t)}{\sigma_{\text{cohort}}(t)} \right)$$

AS-Norm을 적용함으로써 스코어의 통계적 분포가 표준 정규화되며, 극단적인 값(Extreme values)의 영향을 억제하여 시스템의 오수락률(False Acceptance Rate, FAR)과 오거부률(False Rejection Rate, FRR)의 교차 지점인 EER(Equal Error Rate) 및 MinDCF 성능을 세계 최고 수준으로

끌어올릴 수 있다⁶.

6. 파이프라인 통합의 난제: 분리 왜곡(Embedding Distortion)과 결합 학습 전략

음성 분리 모델과 화자 인식 모델을 단순히 이어 붙이는(Cascaded) 직렬 접근법은 이론적으로는 완벽해 보이나, 실제 통합 환경에서는 '임베딩 왜곡(Embedding Distortion)'이라는 심각한 병목을 초래한다.

6.1 임베딩 왜곡 인과관계 및 탈동조화(Decoupled) vs. 결합(Joint) 학습

음성 분리 모델(SepFormer 등)은 여러 음성을 떼어내는 과정에서 필연적으로 원본에는 없는 비선형적 인위적 왜곡(Processing Artifacts)과 기계적인 주파수 탈락을 발생시킨다⁴. 반면 ECAPA-TDNN이나 ERes2Net 같은 화자 인식 모델은 대부분 '깨끗한 단일 발화(Clean speech)'만을 이용해 학습된다⁴. 그 결과 분리된 음성이 화자 인식기의 입력으로 들어갈 때 심각한 도메인 불일치(Mismatch)가 발생하며, 임베딩 공간에서 클래스 경계가 붕괴되어 대조 비교 성능이 급격히 무너진다⁴.

이를 근본적으로 해결하기 위해 학계와 산업계는 다음 두 가지 접근법을 도입한다:

1. 결합 종단간 학습 (**Joint End-to-End Training - EEND-SS**): 독립된 두 모델을 분리하지 않고, 입력부터 음성 분리, 화자 식별, 화자 수 카운팅까지 하나의 다중 작업 학습(Multi-task Learning) 프레임워크로 최적화하는 아키텍처이다⁵⁸. EEND-SS(Joint End-to-End Neural Speaker Diarization and Separation)와 같은 구조에서는 공유 신경망(Shared network)을 거친 후 분리 브랜치와 다이어라이제이션 브랜치로 나뉘며, 모델이 상호 작용하며 분리 과정의 아티팩트가 화자 분류에 미치는 악영향을 스스로 내재적으로 억제하도록 손실을 역전파한다⁵⁸.
2. 탈동조화(Decoupled) 및 타겟 화자 추출 (Target Speaker Extraction, TSE) 방식: 화자 분리 단계의 입력으로 혼합 음성뿐만 아니라, 추출하고자 하는 타겟 화자의 레퍼런스 임베딩(Enrollment vector)을 시각 정보(입술 움직임)나 사전 음성 정보로 함께 인코더(Transformer 기반)에 주입하는 조건부 분리 기법이다³. 이는 순열 문제(Permutation problem)를 아예 회피할 수 있게 하며, 무의미한 다른 화자나 노이즈의 특징은 강제로 억압하여 SV 모델의 부담을 대폭 경감시킨다¹². 더불어 AC-SIM 파이프라인을 활용하여 SV 모델 훈련 데이터 자체에 분리 아티팩트와 잔향을 인위적으로 시뮬레이션 첨가(Artifact-augmented data)함으로써 도메인 격차를 해소할 수 있다²¹.

프로젝트 통합 통찰: 대규모 자본과 학습 인프라가 확보되었다면 EEND-SS와 같은 종단간 결합 훈련을 시도하는 것이 이상적이다⁵⁹, 현실적인 구현 난이도와 유지보수를 고려할 때는 타겟 화자 추출(TSE) 패러다임을 도입하거나, 화자 임베딩 추출망(ERes2NetV2 등)을 분리 모델이 출력한 아티팩트 증강 데이터로 파인튜닝(Fine-tuning)하는 탈동조화(Decoupled) 접근이 단기적으로 가장 압도적인 성능 향상을 보장한다⁴.

7. 오디오 무결성 방어 및 딥페이크 탐지 (Audio Anti-Spoofing) 메커니즘 도입

최근 AI 기술의 민주화로 인해 음성 분리 및 성문 대조 시스템을 겨냥한 위협 지형이 크게 변했다. 악의적 사용자가 TTS(Text-to-Speech) 모델이나 보이스 컨버전(Voice Conversion) 인공지능을 통해 특정인의 목소리를 완벽히 묘사하여 대조 비교 시스템을 우회하려는 논리적 접근(Logical

Access, LA) 딥페이크 공격이 급증하고 있다⁸. 프로젝트를 핀테크, 출입 통제, 포렌식 등 실제 보안 환경에 배포할 목적이라면 파이프라인 전면에 오디오 딥페이크 탐지(Audio Deepfake Detection, ADD) 방어 체계를 병렬로 이중화해야 한다.

7.1 AASIST 프레임워크 및 파운데이션 결합 아키텍처

위조 음성 방어를 위한 현존 최고의 SOTA 아키텍처는 AASIST (Audio Anti-Spoofing using Integrated Spectro-Temporal Graph Attention Networks)이다⁶¹. 이는 시간 도메인(Temporal)과 주파수 스펙트럼(Spectral) 도메인의 비정형적이고 미세한 인공 아티팩트를 동시에 포착하기 위해 그래프 주의 신경망(GAT)과 이기종 적층(Heterogeneous stacking) 메커니즘을 사용한다⁹. 이러한 AASIST 기반 방어 체계는 최근 다음과 같이 고도화되었다.

- **PT-SSL-AASIST (Prompt Tuning & SSL):** Wav2Vec 2.0 (XLS-R)과 같은 대규모 자기 지도 학습(SSL) 프론트엔드를 AASIST 백엔드에 결합하여 성능을 비약적으로 높인 모델이다. 시각적 프롬프트 튜닝(VPT)에 영감을 받아 프롬프트 튜닝 기반 웨이블릿(Wavelet prompt tokens)을 도입함으로써 모든 종류의 위조 음성에 대해 EER 3.58% 수준의 극강의 탐지력을 보여준다⁷.
- **AASIST3 (KAN-Enhanced):** 기존 GAT 신경망의 선형적 한계를 넘기 위해 학습 가능한 B-스플라인 기반의 KAN(Kolmogorov-Arnold Networks)을 주의(Attention) 모듈에 전면 적용하였다⁸. 이를 통해 주파수 전조(Pre-emphasis) 과정에서 인위적 합성 음성이 남기는 가장 고차원적인 매개변수를 추출하여, ASVspoof 2024 벤치마크 환경에서 minDCF를 절반 이상 단축하며 시스템의 절대적 보안성을 담보한다⁸.
- **Speech DF Arena** 검증: 개발된 전체 시스템은 14개의 다양한 딥페이크 데이터셋을 망라하는 Speech DF Arena 벤치마크 프레임워크를 통해 지속적으로 취약성을 점검하고 EER, F1 Score 등의 객관적 지표를 관리해야 한다⁶¹.

8. 최적 오픈소스 툴킷 및 프레임워크 생태계 선정 전략

복잡한 신경망을 처음부터 구현(From scratch)하는 대신, 학계와 글로벌 빅테크 기업들이 검증하고 최적화한 오픈소스 생태계를 통합하여 개발 생산성과 시스템 안정성을 극대화해야 한다.

프레임워크 명칭	주도 주체	주요 지원 모델 및 특징점	프로젝트 도입 시 권장 역할	참고
WeSpeaker (wenet-e2e)	Tencent 및 오픈 커뮤니티	ResNet, ECAPA-TDNN 지원. Kaldi 형식 100% 호환. AS-Norm, PLDA, UMAP 및 HDBSCAN 기반 화자 다이어라이제	성문 패턴 추출, 스코어링 정규화 백엔드 및 전체 파이프라인의 오케스트레이션(Orchestration) 도구로 사용.	66

		이선 알고리즘 기본 내장. Whisper 기반 PMFA 통합에 최적화됨.		
3D-Speaker	Alibaba Damo Academy	ERes2Net, ERes2NetV2, CAM++ 등 최신 화자 임베딩 모델 제공. 온라인(실시간) 특징 추출을 지원해 디스크 I/O 병목 제거. 짧은 음성 구간 성능이 독보적임.	음성 분리 직후 잘게 쪼개진 2~3초의 짧은 오디오 조각들에서 왜곡 없는 고품질 임베딩을 추출하는 핵심 전방 모듈로 사용.	36
SpeechBrain	파이토치 커뮤니티	SepFormer(음 성 분리) 및 ECAPA-TDNN(화자 인식)이 동일 프레임워크에 묶여 있음. 유연한 설계 사상을 가짐.	결합 학습(Joint training) 연구나 다중 태스크 프로토타이핑 을 신속하게 테스트할 때 활용.	5

9. 결론 및 최종 구현 로드맵 제언

본 보고서에서 심층 분석한 "소리 내 다중 화자 음성 분리 및 성문 패턴 기반 대조 비교 시스템" 프로젝트를 오류 없이 성공적으로 완수하고 산업 배포 수준의 강건성을 확보하기 위해서는 다음과 같은 4단계 기술 로드맵을 채택할 것을 강력히 권고한다.

1. 프론트엔드 전처리 및 고효율 음성 분리망 구축: 먼저 긴 스트리밍 데이터에서 불필요한 침묵을 Silero VAD로 제거한 후, DeepFilterNet을 적용해 원시 노이즈를 억제한다²³. 음성 분리 모듈로는 하드웨어 연산량이 충분한 오프라인 환경이라면 MossFormer나 SepFormer를 배치하고, 실시간성 및 메모리 선형성이 필수라면 Mamba-TasNet 기반의 SSM 분리망을 도입하여 화자 순열 문제(PIT)를 해결한다¹⁴.
2. 성문(Voiceprint) 투영 및 초구면 잠재 공간 최적화: 분리로 인해 짧고 불안정해진 시계열 파형에서 고유 특징을 뽑아내기 위해, 다중 스케일 로컬/전역 융합 기술이 적용된

ERes2NetV2를 화자 임베딩 백본으로 기용한다³³. 이때 벡터가 기하학적으로 완벽히 군집하도록 훈련 단계에서 ArcFace (또는 확률론적 Q-Margin) 손실 함수를 강제하여 클래스 간 마진을 극대화한다²⁹.

3. 분리 왜곡 극복 및 백엔드 정규화(**AS-Norm**): 음성 분리기 출력의 아티팩트가 유발하는 '임베딩 왜곡'을 극복하기 위해 분리망의 노이즈를 포함한 증강 데이터로 SV망을 파인튜닝하는 탈동조화 전략을 취한다⁴. 생성된 임베딩은 코사인 유사도로 평가하되, 환경 변동성 보정을 위해 코호트 사칭자 데이터베이스를 활용한 대칭 기반 AS-Norm 스코어 정규화 과정을 무조건 통과하도록 구성하여 FAR 및 FRR을 통제한다⁶.
4. 보안 방어막 및 통합 프레임워크 배포: 인공 합성 음성 우회 공격을 원천 차단하기 위해 파이프라인 초입에 KAN 기반의 AASIST3 또는 프롬프트 튜닝 기반 WPT-XLSR-AASIST 모듈을 연동하여 오디오 생체성 무결성을 1차 검증한다⁸. 마지막으로 이 복잡한 파이프라인의 입출력과 훈련을 WeSpeaker 및 3D-Speaker의 오픈소스 인프라에 통합 구축함으로써, 연구 생산성을 높이고 유지보수의 연속성을 확보한다⁶⁶.

위의 종합적인 아키텍처 결합과 수학적 정규화 전략이 빈틈없이 조화될 때, 본 프로젝트는 어떠한 혼합 잡음이나 적대적 변조 환경에서도 개별 화자의 신원을 명확히 대조·식별해 내는 세계 최고 수준의 오디오 지능 분석 파이프라인으로 거듭나게 될 것이다.

Works cited

1. Advances in Speech Separation: Techniques, Challenges, and, <https://arxiv.org/html/2508.10830v1>
2. Noise-robust Speech Separation with Fast Generative Correction, https://www.isca-archive.org/interspeech_2024/wang24i_interspeech.pdf
3. Speech Separation with Pretrained Frontend to Minimize Domain, <https://arxiv.org/pdf/2411.03085>
4. Elevating Robust Multi-Talker ASR by Decoupling Speaker ... - arXiv, <https://arxiv.org/html/2503.17886v1>
5. ECAPA vs X-Vector in Speaker Recognition - Hugging Face, <https://huggingface.co/blog/norwooodsystems/ecapa-vs-xvector-speaker-recognition-comparison>
6. Trainable Adaptive Score Normalization for Automatic Speaker, https://www.researchgate.net/publication/390569897_Trainable_Adaptive_Score_Normalization_for_Automatic_Speaker_Verification
7. Refining Graph Attention for Speech Deepfake Detection - arXiv, <https://arxiv.org/abs/2507.11777>
8. KAN-Enhanced AASIST Speech Deepfake Detection using SSL, <https://arxiv.org/html/2408.17352v2>
9. Investigating the Impact of Speech Enhancement on Audio ... - arXiv, <https://arxiv.org/html/2603.14767v1>
10. arXiv:2407.15749v1 [eess.AS] 22 Jul 2024, <https://arxiv.org/pdf/2407.15749>
11. Robustness of Speech Separation Models for Similar-pitch Speakers, <https://arxiv.org/html/2407.15749v1>
12. arXiv:2501.01401v1 [eess.AS] 2 Jan 2025, <https://arxiv.org/pdf/2501.01401>
13. Exploring Self-Attention Mechanisms for Speech Separation - arXiv,

- <https://arxiv.org/abs/2202.02884>
14. arXiv:2403.18257v2 [eess.AS] 1 May 2024, <https://arxiv.org/pdf/2403.18257>
 15. [2010.13154] Attention is All You Need in Speech Separation - arXiv, <https://arxiv.org/abs/2010.13154>
 16. speechbrain/spkrec-ecapa-voxceleb - Hugging Face, <https://huggingface.co/speechbrain/spkrec-ecapa-voxceleb>
 17. arXiv:2206.09507v2 [eess.AS] 15 Jan 2024, <https://arxiv.org/pdf/2206.09507>
 18. MossFormer2: Combining Transformer and RNN-Free Recurrent, <https://arxiv.org/html/2312.11825v2>
 19. Speech Separation using Neural Audio Codecs with Embedding Loss, <https://arxiv.org/html/2411.17998v1>
 20. PixIT: Joint Training of Speaker Diarization and Speech Separation, <https://arxiv.org/html/2403.02288v1>
 21. Improving Generalization of Speech Separation in Real-World, <https://arxiv.org/html/2408.16126v1>
 22. DeepFilterNet Vs DeepFilterNet2 Vs DeepFilterNet3 Vs RNNoise, <https://noisereducerai.com/blogs/deepfilternet-ai-noise-reduction/>
 23. Deepfilternet 3: Noise Suppression - Ai Adoption Agency, <https://aiadoptionagency.com/deepfilternet-3-noise-suppression/>
 24. deepfilternet · GitHub Topics, <https://github.com/topics/deepfilternet?l=python&o=asc&s=updated>
 25. Deepfilternet Parameters, Sample Rate, Latency, Audio Length, <https://noisereducerai.com/blogs/deepfilternet-parameters/>
 26. Ultra-Tiny Speech Activity Detection for Edge Deployment - arXiv, <https://arxiv.org/pdf/2607.25870>
 27. VibeVoice-ASR Technical Report - arXiv, <https://arxiv.org/html/2601.18184v2>
 28. Voice Activity Detection on Italian Language - CEUR-WS.org, https://ceur-ws.org/Vol-3878/111_main_long.pdf
 29. ArcFace: Additive Angular Margin Loss for Deep Face Recognition, https://www.researchgate.net/publication/322674945_ArcFace_Additive_Angular_Margin_Loss_for_Deep_Face_Recognition
 30. ECAPA-TDNN Speaker Recognition Model - ModelScope, https://modelscope.cn/models/iic/speech_ecapa-tdnn_sv_en_voxceleb_16k
 31. wespeaker/docs/speaker_recognition_papers.md at master - GitHub, https://github.com/wenet-e2e/wespeaker/blob/master/docs/speaker_recognition_papers.md
 32. ERes2NetV2 Speaker Recognition Model - ModelScope, https://modelscope.cn/models/iic/speech_eres2netv2_sv_zh-cn_16k-common/su_mmary
 33. [2406.02167] ERes2NetV2: Boosting Short-Duration Speaker ... - arXiv, <https://arxiv.org/abs/2406.02167>
 34. ERes2NetV2: Boosting Short-Duration Speaker Verification, https://www.researchgate.net/publication/383651341_ERes2NetV2_Boosting_Short-Duration_Speaker_Verification_Performance_with_Computational_Efficiency
 35. ERes2NetV2: Boosting Short-Duration Speaker Verification ... - arXiv,

- <https://arxiv.org/pdf/2406.02167>
36. An Open-Source Toolkit for Multimodal Speaker Verification ... - arXiv,
<https://arxiv.org/html/2403.19971v2>
 37. An Open-Source Toolkit for Multimodal Speaker Verification ... - arXiv,
<https://arxiv.org/html/2403.19971v3>
 38. Whisper Speaker Identification (WSI) - PyPI,
<https://pypi.org/project/whisper-speaker-id/>
 39. Whisper-PMFA: Partial Multi-Scale Feature Aggregation for Speaker,
https://www.isca-archive.org/interspeech_2024/zhao24f_interspeech.pdf
 40. Whisper-PMFA: Partial Multi-Scale Feature Aggregation for Speaker,
https://www.researchgate.net/publication/383653497_Whisper-PMFA_Partial_Multi-Scale_Feature_Aggregation_for_Speaker_Verification_using_Whisper_Models
 41. Whisper Speaker Identification Framework | PDF | Speech Recognition,
<https://www.scribd.com/document/839677455/WHISPER-SPEAKER-IDENTIFICATION-LEVERAGING-PRE-TRAINED-MULTILINGUAL-TRANSFORMERS-FOR-ROBUST-SPEAKER-EMBEDDINGS>
 42. DENG 2019: ArcFace - Additive Angular Margin Loss for Face,
<https://www.studocu.vn/vn/document/truong-dai-hoc-dai-nam/tieng-anh/deng-2019-arcface-additive-angular-margin-loss-for-face-recognition/145619375>
 43. Alpha Divergence Losses for Biometric Verification - arXiv,
<https://arxiv.org/html/2511.13621v1>
 44. Speaker Representation Learning via Contrastive Loss with,
<https://www1.se.cuhk.edu.hk/~hccl/publications/pub/Speaker%20Representation%20Learning%20via%20Contrastive%20Loss%20with%20Maximal%20Speaker%20Separability.pdf>
 45. ArcFace loss function for Deep Face Recognition by payyavula,
<https://medium.com/@payyavulasaiprakash/arcface-loss-function-for-deep-face-recognition-e1ff5e173b52>
 46. Deep Speaker Embedding with Long Short Term Centroid Learning,
https://www.isca-archive.org/interspeech_2020/peng20b_interspeech.pdf
 47. Advancing speaker embedding learning: Wespeaker toolkit for,
https://www.researchgate.net/publication/382256675_Advancing_speaker_embedding_learning_Wespeaker_toolkit_for_research_and_production
 48. A Stage-Wise Learning Strategy with Fixed Anchors for Robust,
<https://arxiv.org/html/2510.18530v2>
 49. Cross-Lingual Speaker Verification for the TidyVoice 2026 Challenge,
<https://arxiv.org/pdf/2607.22923>
 50. Trainable Adaptive Score Normalization for Automatic Speaker,
<https://arxiv.org/html/2504.04512v1>
 51. Tail-Aware Extreme Value Normalization for Speaker Verification,
https://www.researchgate.net/publication/404608174_AS-EVNorm_Tail-Aware_Extreme_Value_Normalization_for_Speaker_Verification
 52. NIST-SRE-2019/Score-Normalization.ipynb at master - GitHub,
<https://github.com/noiseux1523/NIST-SRE-2019/blob/master/Score-Normalization.ipynb>

53. Speaker adaptive cohort selection for Tnorm in text-independent,
<https://www.ll.mit.edu/r-d/publications/speaker-adaptive-cohort-selection-tnorm-text-independent-speaker-verification>
54. Cross similarity measurement for speaker adaptive test,
<https://jcuapt.bupt.edu.cn/CN/Y2008/V15/I2/130>
55. From adaptive score normalization to adaptive data ... - ISCA Archive,
https://www.isca-archive.org/interspeech_2023/cumani23_interspeech.html
56. Analysis of Score Normalization in Multilingual Speaker Recognition,
https://www.fit.vut.cz/research/group/speech/public/publi/2017/matejka_interspeech2017_IS170803.pdf
57. Daily Papers - Hugging Face,
<https://huggingface.co/papers?q=speech%20separation>
58. TS-SEP: Joint Diarization and Separation Conditioned on Estimated,
<https://arxiv.org/pdf/2303.03849>
59. EEND-SS: Joint End-to-End Neural Speaker Diarization and Speech,
<https://arxiv.org/html/2203.17068v2>
60. AASIST3: KAN-Enhanced AASIST Speech Deepfake Detection,
<https://arxiv.org/html/2408.17352v1>
61. A Leaderboard for Speech DeepFake Detection Models - arXiv,
<https://arxiv.org/pdf/2509.02859>
62. Official PyTorch implementation of "AASIST: Audio Anti-Spoofing",
<https://github.com/clovaai/aasist>
63. Refining Graph Attention for Speech Deepfake Detection - arXiv,
<https://arxiv.org/html/2507.11777v1>
64. Detect All-Type Deepfake Audio: Wavelet Prompt Tuning for,
<https://ojs.aaai.org/index.php/AAAI/article/view/40907/44868>
65. AASIST3: KAN-Enhanced AASIST Speech Deepfake Detection,
<https://arxiv.org/abs/2408.17352>
66. wenet-e2e/wespeaker: Research and Production Oriented ... - GitHub,
<https://github.com/wenet-e2e/wespeaker>
67. jin1258804/3D-Speaker - Gitee, <https://gitee.com/jin1258804025/3D-Speaker>
68. GitHub - modelscope/3D-Speaker: A Repository for Single,
<https://github.com/alibaba-damo-academy/3D-Speaker?spm=a2c6h.13046898.publish-article.11.4ff46ffaW8zrmC>